



## Tópicos em Inteligência Artificial

Prof. Bruno M. Nogueira

*Faculdade de Computação - UFMS*

### Trabalho - Geração de textos usando Word Embeddings e RNN

#### Objetivo

Implementar e avaliar um modelo de geração de texto em português utilizando **LSTM (Long Short-Term Memory)**. O trabalho deve explorar:

- Construção de um corpus temático (ex.: letras de músicas, receitas, discursos políticos, notícias).
- Treinamento de um modelo base com embeddings **do zero**.
- Treinamento de uma variante com **embeddings pré-treinados** ou tokenização em subpalavras.
- Avaliação quantitativa por **perplexidade** e qualitativa por amostras de texto geradas.
- Análise crítica de erros, limitações e vieses do modelo e do corpus.

#### Descrição da Tarefa

Vocês deverão implementar um modelo de linguagem neural baseado em LSTM que seja capaz de gerar texto no estilo de um corpus específico escolhido pelo grupo. Exemplos de corpora possíveis:

- **Letras de músicas brasileiras:** sites como <https://www.letras.mus.br/> ou <https://www.vagalume.com.br/>.
- **Receitas:** sites como <https://www.tudogostoso.com.br/> ou <https://panelinha.com.br/>.
- **Discursos políticos:** atas e diários oficiais disponíveis em portais do governo (ex.: <https://www.camara.leg.br/>).
- **Textos jornalísticos de domínio público.**

## Sugestão para coleta de dados (web scraping)

- Utilizar BeautifulSoup ou requests-html em Python para extrair o conteúdo das páginas.
- Filtrar apenas os textos principais (sem propagandas ou menus).
- Normalizar: converter para minúsculas, remover tags HTML, espaços extras e caracteres irrelevantes.
- Gerar um arquivo de texto consolidado (`corpus.txt`) com todas as amostras concatenadas.

## Uso de embeddings pré-treinados

Para enriquecer o modelo, recomenda-se o uso de embeddings já treinados em português, como:

- **fastText pt-BR** (<https://fasttext.cc/docs/en/crawl-vectors.html>).
- **Word2Vec em português** (disponível em <https://nilc.icmc.usp.br/embeddings>).
- **GloVe em português** (treinado em corpora da web e Wikipedia).

A incorporação pode ser feita da seguinte forma:

1. Mapear o vocabulário do corpus aos vetores disponíveis.
2. Inicializar a camada de embeddings do modelo LSTM com os vetores carregados.
3. Congelar essa camada nas primeiras épocas e, depois, liberar para *fine-tuning*.

## Métrica de Avaliação: Perplexidade

A **perplexidade (PPL)** é a métrica padrão em modelos de linguagem. Ela é definida como:

$$\text{PPL} = \exp \left( -\frac{1}{N} \sum_{i=1}^N \log p(w_i \mid w_{<i}) \right)$$

onde  $N$  é o número de tokens e  $p(w_i \mid w_{<i})$  é a probabilidade prevista para a próxima palavra. Intuitivamente, a perplexidade mede o quão “surpreso” o modelo fica com os dados reais:

- PPL baixa  $\rightarrow$  modelo prevê bem o corpus.
- PPL alta  $\rightarrow$  modelo ainda “se confunde”.

O relatório deve apresentar PPL no conjunto de validação e de teste, comparando:

- **Baseline (do zero).**
- **Variante (com embeddings pré-treinados ou subwords).**

## Etapas do Trabalho

1. **Pré-processamento:** limpeza, tokenização, divisão em treino/validação/teste.
2. **Implementação do modelo LSTM:** camada de embeddings + LSTM + projeção linear.
3. **Treinamento:** otimização com Adam, monitorando perplexidade.
4. **Geração:** amostras de texto com diferentes temperaturas (0.7, 1.0, 1.3).
5. **Comparação de variantes:** baseline vs embeddings pré-treinados.
6. **Avaliação:** quantitativa (PPL) e qualitativa (coerência dos textos).
7. **Análise crítica:** erros comuns, repetições, vieses do corpus.

## Entregáveis

- **Notebook executável** (PyTorch ou TensorFlow).
- **Relatório (5–8 páginas)** contendo:
  - Introdução.
  - Materiais e métodos (descrição do corpus, tokenização, modelo, embeddings).
  - Resultados e discussão (PPL, exemplos de geração, gráficos, limitações, erros, vieses).
  - Conclusões.
  - Referências.
- **Amostras de texto gerado** em diferentes configurações de temperatura.
- **Apresentação em vídeo**, com duração máxima de 7 minutos, por um dos membros do grupo. O link da apresentação deverá estar na última página do relatório.

## Critérios de Avaliação

- Pré-processamento e organização do corpus (15).
- Implementação do modelo LSTM (20).
- Comparação baseline vs variante (20).
- Avaliação (PPL + amostras) (20).
- Análise crítica (erros, vieses, ética) (15).
- Reprodutibilidade e clareza (10).

**Bônus (+10 pts):** uso de GRU/beam search, regularização extra, ou tokenização em subwords.

## Prazo de Entrega

O trabalho tem limite de entrega até as **23:59 o dia 12/10/2025**.

**ATENÇÃO:** Todas as entregas serão submetidas a análise de plágio em sistemas próprios para isso (textos e scripts). Não será tolerado plágio de quaisquer fontes, mesmo que parcial. Quando detectado plágio, o trabalho terá nota zero.

Havendo qualquer dúvida, consulte o professor.

**Bom trabalho!**